HO CHI MINH CITY UNIVERSITY OF TECHNOLOGY – VNU-HCM
FACULTY OF COMPUTER SCIENCE AND ENGINEERING



Course: CO5177 – Programming Foundations for Data Analysis and Visualization

Semester 261, Academic Year 2026–2027

BÁO CÁO BÀI TẬP LỚN

Phân tích và dự báo chuỗi thời gian

Chuỗi thời gian (Time Series)

Group: DataInsight
Lecturer: Lê Thành Sách
Landing page: https://trthminh.github.io/CO5177/

Name	Student ID	Project
Trương Thanh Minh	2580893	Time series
Tô Anh Phát	2580894	Text
Trần Lê Hoàng Long	2570443	Tabular

TP. Hồ Chí Minh, tháng 11 năm 2026

Mục lục

1 Phân tích và dự báo chuỗi thời gian **1**

1.1 Bài toán và mục tiêu . . . 1
1.2 Tập dữ liệu . . . 1
1.3 Chất lượng dữ liệu và làm sạch . . . 2
1.4 Phân tích khám phá dữ liệu (EDA) . . . 3
1.4.1 Toàn cảnh và phân phối của biến mục tiêu . . . 3
1.4.2 Mùa vụ theo giờ, theo tuần và theo tháng . . . 4
1.4.3 Phân rã mùa vụ (MSTL) . . . 5
1.4.4 Tự tương quan và tính dừng . . . 6
1.4.5 Câu hỏi 1: Thời tiết xấu làm lưu lượng giảm bao nhiêu? . . . 7
1.4.6 Câu hỏi 2: Ngày lễ làm lưu lượng giảm bao nhiêu, và mọi ngày lễ có như nhau? . . . 8
1.4.7 Câu hỏi 3: Thống kê nào phát hiện được đoạn đóng đường? . . . 9
1.5 Chuẩn bị dữ liệu . . . 10
1.5.1 Tạo đặc trưng . . . 10
1.5.2 Chia train / validation / test theo thời gian . . . 11
1.5.3 Mã hóa, chuẩn hóa và chống rò rỉ . . . 12
1.6 Mô hình và thiết lập thực nghiệm . . . 12
1.7 Kết quả và đánh giá . . . 13
1.7.1 So sánh mô hình trên tập validation . . . 13
1.7.2 Kết quả trên tập test . . . 14
1.7.3 Phân tích lỗi và tầm quan trọng của đặc trưng . . . 15
1.8 Kết luận . . . 17
1.9 Hạn chế và hướng phát triển . . . 17
1.10 Tài liệu tham khảo . . . 18

Chương 1

Phân tích và dự báo chuỗi thời gian

1.1 Bài toán và mục tiêu

Sở Giao thông Minnesota (MnDOT) đếm mọi xe đi qua trạm đếm tự động ATR 301 trên các làn hướng tây của cao tốc Interstate 94, khoảng giữa Minneapolis và St Paul (Mỹ). Chương này dự báo `traffic_volume`, tức số xe trong **giờ kế tiếp** (`HORIZON` = 1), từ lưu lượng trong quá khứ, lịch (giờ, thứ, ngày lễ) và thời tiết quan sát được một giờ trước đó. Một dự báo trước một giờ đáng tin cậy hỗ trợ điều tiết đèn vào cao tốc (ramp metering), ứng phó sự cố và cung cấp thông tin thời gian di chuyển cho tài xế.

Đây là bài toán hồi quy trên chuỗi thời gian theo giờ. Các mô hình được so sánh trên một giai đoạn validation theo thời gian bằng **MAE** (xe/giờ, metric quyết định), RMSE, MAPE, R^2 và **skill** so với dự báo naive,

$$\text{skill} = 1 - \frac{\text{MAE}_{\text{model}}}{\text{MAE}_{\text{naive}}},$$

trong đó skill dương nghĩa là mô hình tốt hơn dự báo naive. Mô hình được chọn chỉ được chấm điểm một lần trên tập test. MAE được ưu tiên hơn MAPE vì ban đêm chỉ có vài trăm xe, nên một sai số tuyệt đối nhỏ lúc đêm khuya đã thành sai số tương đối rất lớn.

1.2 Tập dữ liệu

- Tên: Metro Interstate Traffic Volume (Kaggle, bản gốc từ UCI Machine Learning Repository).
- URL: https://www.kaggle.com/datasets/pooriamst/metro-interstate-traffic-volume; notebook tải đúng file gzip này từ kho UCI nên không cần API key.
- Nguồn: trạm ATR 301 của MnDOT; thời tiết theo giờ từ OpenWeatherMap; ngày lễ của Mỹ và bang Minnesota.
- Giai đoạn và tần suất: 02/10/2012 – 30/09/2018, theo giờ, giờ địa phương (US Central).
- Kích thước: 48,204 dòng, 9 cột. Theo lịch, giai đoạn này phải có 52,551 giờ.

- Biến mục tiêu: `traffic_volume` (0 đến 7,280 xe/giờ, trung bình $\approx$ 3,260). Các biến khác: `holiday`, `temp` (Kelvin), `rain_1h`, `snow_1h` (mm), `clouds_all` (%), `weather_main` (11 nhóm) và `weather_description` (38 giá trị).
- Giấy phép: CC BY 4.0 (J. Hogue, UCI Machine Learning Repository, 2019).

Trong chương này số được viết theo quy ước quốc tế (dấu phẩy ngăn hàng nghìn, dấu chấm thập phân) để khớp với các hình.

1.3 Chất lượng dữ liệu và làm sạch

Một chuỗi thời gian đều cần đúng một dòng cho mỗi bước thời gian và không thiếu bước nào, vì lag và cửa sổ trượt đếm theo dòng chứ không theo thời gian. Bảng 1.1 liệt kê các vấn đề phát hiện và cách xử lý.

Bảng 1.1: Các vấn đề chất lượng dữ liệu và cách xử lý

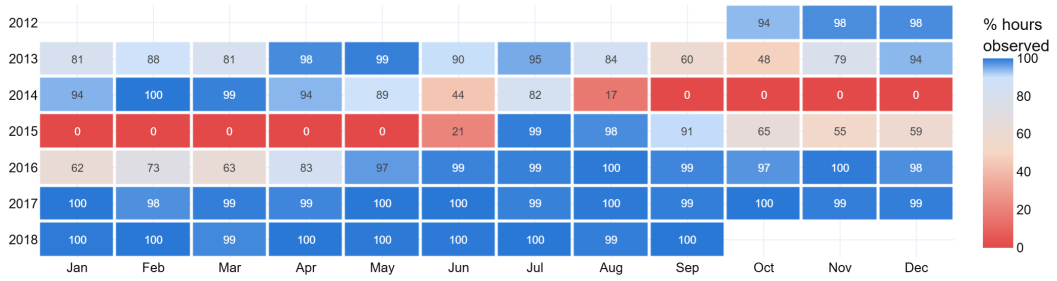
Vấn đề	Quy mô	Cách xử lý
Trùng mốc giờ (nhiều hiện tượng thời tiết trong một giờ)	7,629 / 48,204 dòng (15.8%)	Gộp về một dòng mỗi giờ, giữ số hiện tượng trong `n_weather`
Thiếu giờ (2012–2018)	11,976 giờ (22.8%) trong 2,588 đoạn, dài nhất 7,386 giờ ($\approx$ 10 tháng)	Chỉ giữ 01/2016 – 09/2018
Thiếu giờ trong giai đoạn đã chọn	1,012 / 24,096 giờ (4.2%), đoạn dài nhất 9 giờ	Reindex theo giờ, nội suy tuyến tính theo thời gian, cờ `is_imputed`
Lỗi cảm biến	10 giờ `temp` = 0 K, 1 giờ `rain_1h` = 9,831 mm	Đổi thành NaN rồi nội suy
Nhãn ngày lễ chỉ ở dòng 00:00	61 dòng	Lan nhãn cho cả 24 giờ trong ngày
Ngoại lai của `traffic_volume`	1,016 giờ (4.2%) theo rolling median/MAD	Giữ nguyên giá trị (sự kiện thật), cờ `is_outlier` để phân tích lỗi

Dòng trùng. Mọi mốc thời gian đều đọc được và đúng thứ tự, nhưng 15.8% số dòng lặp lại một giờ đã có. Trong một giờ bị trùng, lưu lượng không bao giờ khác nhau; chỉ `weather_main` và `weather_description` thay đổi (ở 98% số nhóm). Khi trong cùng một giờ có nhiều hiện tượng thời tiết (ví dụ mưa nhỏ, sương mù và giông), nguồn dữ liệu ghi mỗi hiện tượng thành một dòng và chép lại nguyên lưu lượng. Vì vậy gộp các dòng là chính xác với biến mục tiêu; ta giữ hiện tượng đầu tiên và lưu số hiện tượng vào `n_weather`.

Giai đoạn nghiên cứu. Phần lớn các đoạn thiếu chỉ dài một giờ (85% số đoạn), nhưng 64% số giờ bị thiếu đến từ các đoạn dài hơn một tuần, nhất là 7,386 giờ liên tiếp từ tháng 8/2014 đến tháng 6/2015 (Hình 1.1). Không phép nội suy nào dựng lại được mười tháng, và lag theo tuần y_{t-168} sẽ sai quanh những lỗ hổng như vậy. Do đó phân tích chỉ giữ giai đoạn **01/01/2016 –**

30/09/2018: 2 năm 9 tháng, đủ để mỗi mùa xuất hiện ít nhất hai lần. Trong giai đoạn này 95.8% số giờ có dữ liệu (so với 61.5% trước đó) và đoạn thiếu dài nhất chỉ 9 giờ.

Nội suy. Các đoạn thiếu dài tối đa 12 giờ (tức mọi đoạn thiếu trong giai đoạn đã chọn) được điền bằng nội suy tuyến tính theo thời gian với cột số và forward fill với cột phân loại. Lưu lượng và thời tiết thay đổi liên tục, còn forward fill sẽ "đóng băng" một giờ cao điểm đang tăng hoặc giảm; ngược lại, không thể lấy trung bình của hai nhãn thời tiết. Mỗi giờ được điền mang cờ `is_imputed`, và mô hình chỉ được chấm điểm trên các giờ quan sát thật. Các giá trị vô lý về mặt vật lý (0 K, 9,831 mm mưa trong một giờ, khoảng 30 lần kỷ lục thế giới) là lỗi đo: chúng được đổi thành NaN và nội suy theo cùng cách. Cuối cùng, tên ngày lễ chỉ được ghi ở dòng 00:00 của mỗi ngày lễ, nên được lan ra cả ngày; bước này chỉ dùng lịch nên không làm rò rỉ thông tin tương lai.



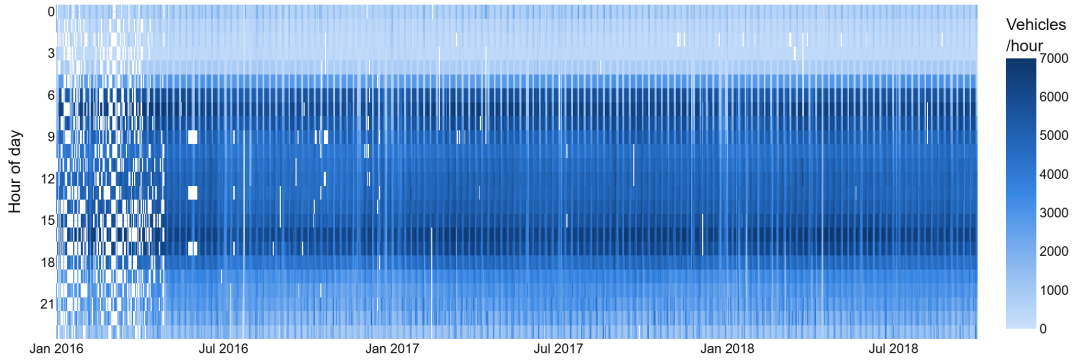
Hình 1.1: Tỷ lệ giờ có dữ liệu theo tháng: 2014–2015 gần như trống, còn 2016–2018 gần như đầy đủ (95.8% số giờ có dữ liệu, đoạn thiếu dài nhất 9 giờ).

1.4 Phân tích khám phá dữ liệu (EDA)

Mọi phân tích dưới đây dùng giai đoạn nghiên cứu (24,096 giờ). Tổng theo ngày, phân rã mùa vụ và ACF cần chuỗi không có lỗ hổng nên dùng một bản sao đã nội suy.

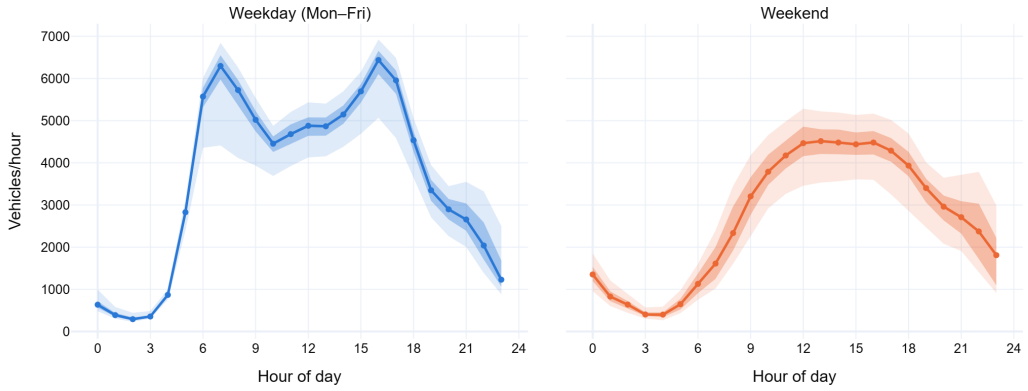
1.4.1 Toàn cảnh và phân phối của biến mục tiêu

Hình 1.2 vẽ toàn bộ các giờ của giai đoạn cùng lúc: mỗi cột là một ngày, mỗi hàng là một giờ trong ngày. Các dải ngang đậm quanh 6–8h và 15–17h là giờ cao điểm sáng và chiều, bị cắt đều đặn bởi các sọc dọc nhạt (thứ Bảy và Chủ nhật). Những đường trắng đơn lẻ giữa tuần là ngày lễ, bão tuyết hoặc đóng đường. Không vùng nào đậm dần hay nhạt dần theo thời gian, nên chuỗi **không có xu hướng dài hạn**; trung bình ngày giữ quanh 3,300 xe/giờ suốt ba năm, chỉ giảm ngắn quanh dịp năm mới.



Hình 1.2: Mọi giờ của 2016–2018: cao điểm ngày thường, sọc nhạt cuối tuần, ngày lễ và đóng đường hiện thành đường trắng; không có xu hướng dài hạn.

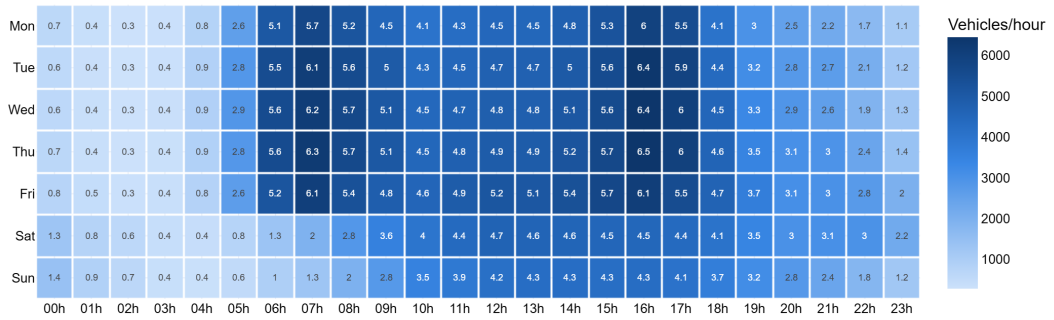
Phân phối của `traffic_volume` có **hai đỉnh**: 21.9% số giờ có dưới 1,000 xe (ban đêm) và 44.7% có từ 4,000 xe trở lên (ban ngày). Độ lệch chuẩn ($\approx$ 1,970) bằng khoảng 60% trung bình ($\approx$ 3,300). Tuy nhiên, trong cùng một giờ của ngày, độ phân tán lại hẹp (Hình 1.3): phần lớn biến động được giải thích bởi đồng hồ chứ không phải nhiễu. Vì vậy mô hình bắt buộc phải biết giờ, qua đặc trưng lịch hoặc các lag y_{t-24} và y_{t-168}.



Hình 1.3: Phân phối theo giờ trong ngày (dải đậm = 50% ở giữa, dải nhạt = 5–95%, đường = trung vị): trong cùng một giờ độ phân tán hẹp, nên giờ giải thích phần lớn biến động.

1.4.2 Mùa vụ theo giờ, theo tuần và theo tháng

Giờ đông nhất (16h, $\approx$ 5,740 xe) gấp khoảng **15 lần** giờ vắng nhất (3h, $\approx$ 380), thứ Sáu đông gấp 1.5 lần Chủ nhật, trong khi tháng đông nhất (tháng 3) chỉ hơn tháng vắng nhất (tháng 1) khoảng **12%**. Hai đỉnh 6–7h và 15–17h chỉ có từ thứ Hai đến thứ Sáu (đi làm); cuối tuần chỉ có một đỉnh rộng quanh trưa (Hình 1.4). Hình dạng của một ngày thường gần như giống nhau ở mọi mùa; khác biệt rõ nhất là đỉnh sáng mùa đông thấp hơn khoảng 6%. Như vậy chu kỳ ngày và tuần chi phối chuỗi và phải được mã hóa, còn chu kỳ năm chỉ là hiệu chỉnh nhỏ (tháng dạng sin/cos).



Hình 1.4: Lưu lượng trung bình (nghìn xe/giờ) theo thứ × giờ: đỉnh 7h và 16h chỉ có từ thứ Hai đến thứ Sáu.

1.4.3 Phân rã mùa vụ (MSTL)

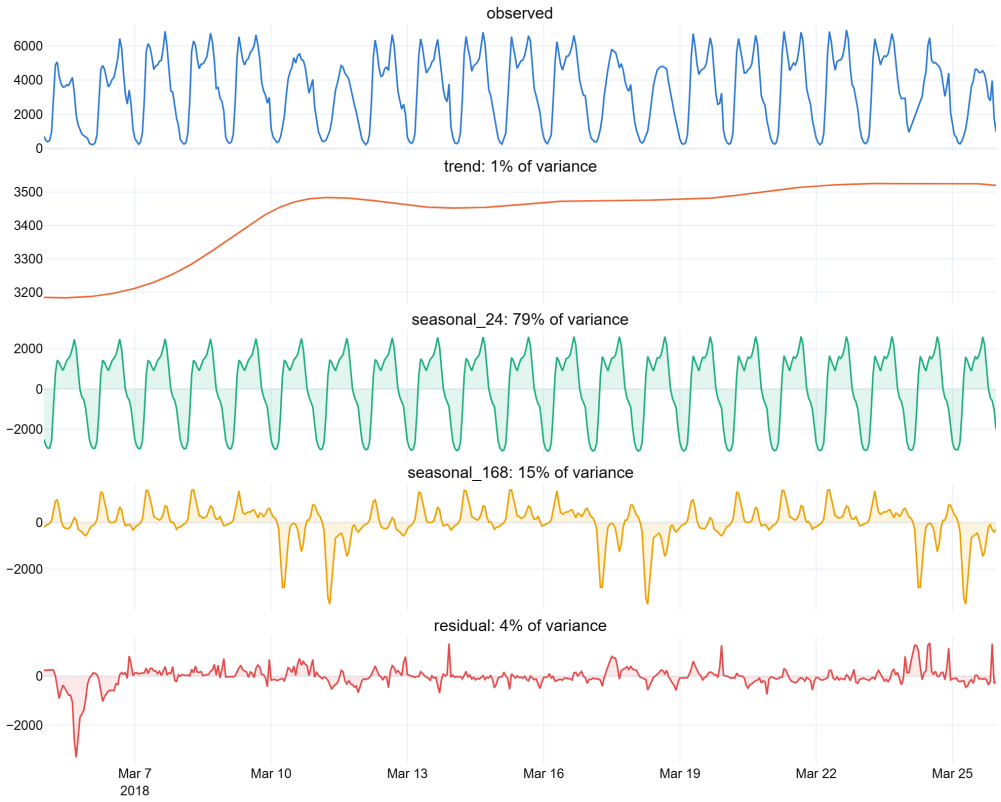
Chuỗi có thể xem là tổng của các lớp

$$y_t = T_t + S_t^{(24)} + S_t^{(168)} + R_t,$$

gồm xu hướng biến đổi chậm T_t, mùa vụ ngày $S_t^{(24)}$, mùa vụ tuần $S_t^{(168)}$ và phần dư R_t. MSTL (Multiple Seasonal-Trend decomposition using LOESS) lần lượt tách hai chu kỳ lồng nhau, điều mà STL thông thường không làm được. Hai đại lượng đo tầm quan trọng của mỗi lớp: tỷ lệ phương sai của nó so với phương sai của y, và độ mạnh mùa vụ $F_S = \max\left(0,\ 1 - \mathrm{Var}(R)/\,\mathrm{Var}(S+R)\right)$ (Wang, Smith và Hyndman, 2006).

Bảng 1.2: Phân rã MSTL trên giai đoạn nghiên cứu (chu kỳ 24 và 168 giờ)

Thành phần	Tỷ lệ phương sai (%)	Độ mạnh mùa vụ (0–1)
Xu hướng	1.2	–
Mùa vụ ngày (24 giờ)	79.0	0.953
Mùa vụ tuần (168 giờ)	15.4	0.798
Phần dư	3.9	–

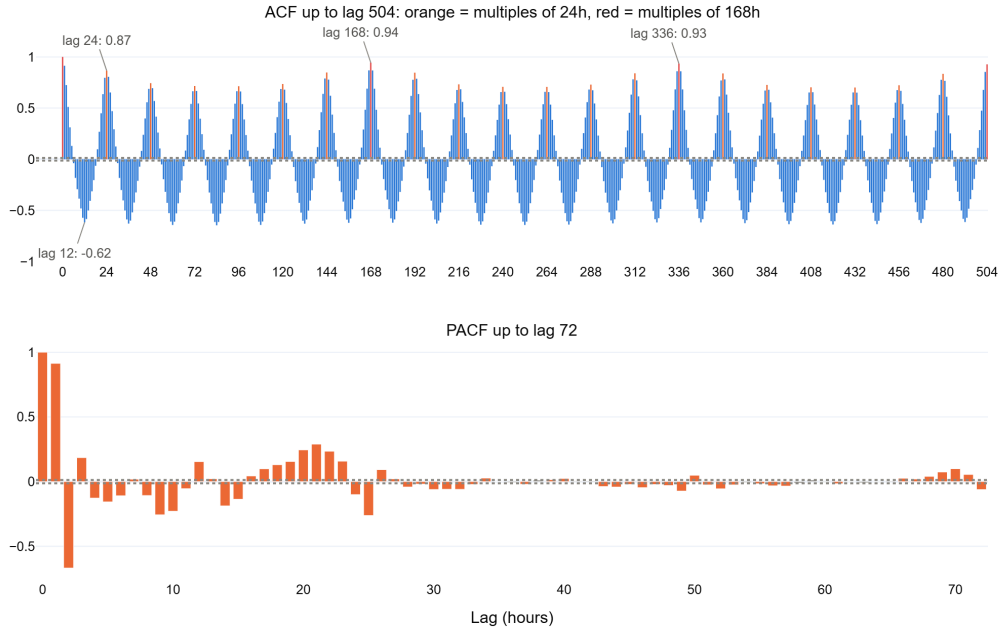


Hình 1.5: MSTL trong ba tuần tháng 3/2018: xu hướng gần như không đổi, mùa vụ ngày lặp lại mỗi ngày, mùa vụ tuần giảm vào cuối tuần, còn phần dư nhỏ với vài đỉnh ở các giờ bất thường.

Nói đơn giản, **chỉ cần biết giờ và thứ là đã giải thích được khoảng 95% biến động** (Bảng 1.2, Hình 1.5); chỉ phần dư (sự kiện, thời tiết) là khó. Xu hướng gần như phẳng nên không cần sai phân để khử xu hướng. Thứ mô hình phải nắm được là hai chu kỳ lồng nhau; riêng chu kỳ ngày đã dao động khoảng 5,300 xe.

1.4.4 Tự tương quan và tính dừng

Hàm tự tương quan $\text{ACF}(k) = \text{corr}(y_t, y_{t-k})$ có dạng sóng chu kỳ 24 giờ (Hình 1.6): âm ở lag 12 (-0.62, ngày so với đêm), cao ở lag 24 (0.87) và cao nhất ở **lag 168 (0.94)**. "Cùng giờ tuần trước" giống hiện tại hơn "cùng giờ hôm qua", vì hôm qua có thể là ngày cuối tuần. PACF lớn ở lag 1 (0.91) và âm mạnh ở lag 2 (-0.67), gợi ý phần tự hồi quy bậc 2–3, còn hai chu kỳ được xử lý riêng. Do đó các lag được dùng làm đặc trưng là `LAGS` = 1, 2, 3, 24, 168.



Hình 1.6: Tự tương quan đạt đỉnh mỗi 24 giờ và cao nhất ở 168 giờ (0.94): chu kỳ ngày và chu kỳ tuần. PACF tắt sau vài lag đầu.

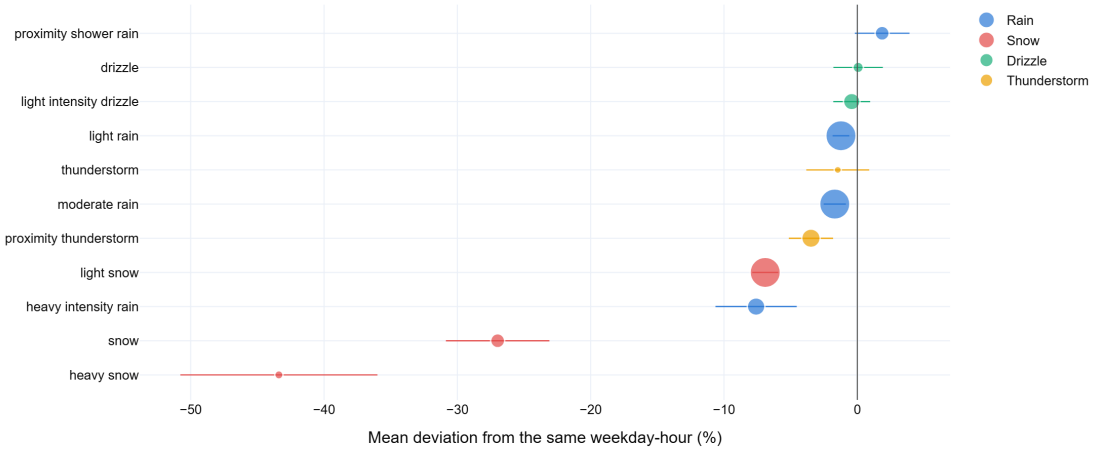
Hai kiểm định bổ sung cho nhau được dùng để kiểm tra tính dừng: ADF (giả thuyết không: có nghiệm đơn vị) và KPSS (giả thuyết không: chuỗi dừng). ADF bác bỏ nghiệm đơn vị cho chuỗi gốc, chuỗi đã khử mùa vụ và chuỗi sai phân tuần ($p \approx 0$), nên không có xu hướng dạng bước ngẫu nhiên. KPSS vẫn bác bỏ tính dừng với chuỗi gốc ($p = 0.03$) và chuỗi đã khử mùa vụ ($p = 0.01$) vì mức trung bình trôi chậm theo mùa và KPSS rất nhạy khi $n \approx 24{,}000$; chuỗi sai phân tuần $y_t - y_{t-168}$ qua được cả hai kiểm định. Hệ quả là mô hình ARIMA không cần sai phân thường ($d = 0$), nhưng các chu kỳ phải được xử lý tường minh. Một seasonal ARIMA với chu kỳ $m = 168$ quá nặng để ước lượng trên khoảng 17,000 giờ huấn luyện, nên Mục 1.6 dùng các số hạng Fourier thay thế.

1.4.5 Câu hỏi 1: Thời tiết xấu làm lưu lượng giảm bao nhiêu?

Tương quan thô bị lịch gây nhiễu: sương mù hay xảy ra lúc rạng sáng, khi vốn đã vắng xe. Vì vậy mỗi giờ ban ngày (6h–20h, không phải ngày lễ, có dữ liệu thật) được so với trung vị của cùng thứ và cùng giờ:

$$\text{chênh lệch}_t = \frac{y_t - \text{median}(y \mid \text{thứ}, \text{giờ})}{\text{median}(y \mid \text{thứ}, \text{giờ})}.$$

Trên 13,948 giờ ban ngày, phần lớn loại thời tiết chỉ làm lưu lượng lệch dưới 2–3%, và tương quan giữa các biến thời tiết dạng số với độ chênh lệch đều dưới 0.13 về trị tuyệt đối. Ngoại lệ rõ rệt là **tuyết: trung bình** -10.6% (879 giờ, khoảng tin cậy 95% là ± 1.1 điểm phần trăm), và -13.6% với mọi giờ mưa hoặc tuyết "heavy". Ảnh hưởng tăng theo cường độ (Hình 1.7): tuyết nhẹ $\approx -7\%$, tuyết $\approx -27\%$ và **tuyết lớn** $\approx -43\%$; mưa lớn $\approx -8\%$, còn mưa nhẹ và mưa vừa gần như không ảnh hưởng. Nhiệt độ chỉ liên hệ yếu với tổng lưu lượng ngày ($r = 0.14$ vào ngày thường).



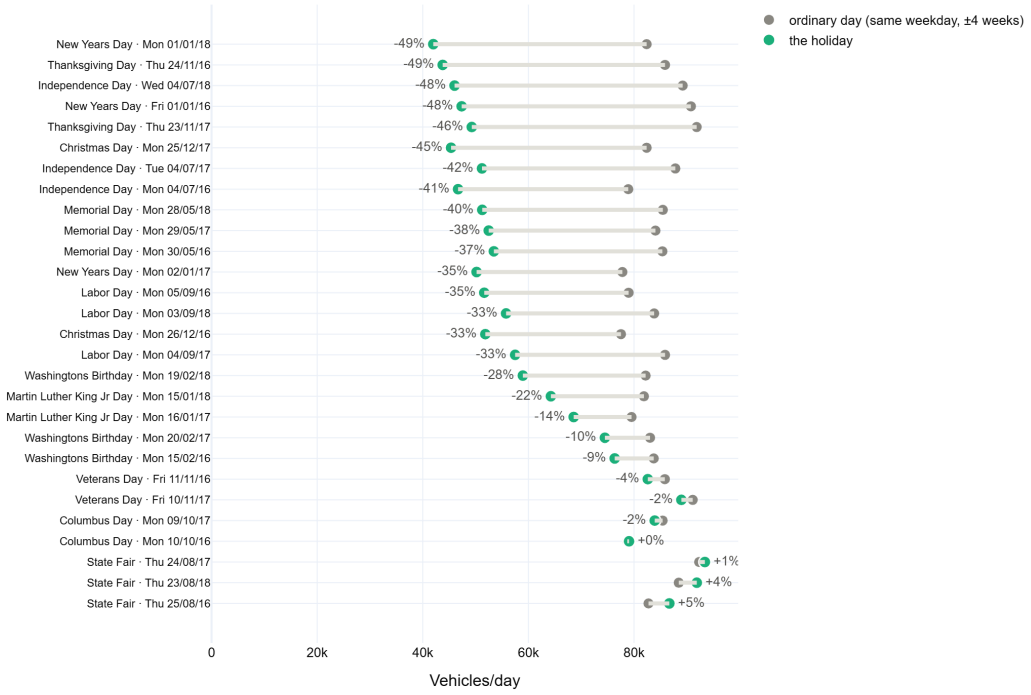
Hình 1.7: Chênh lệch so với cùng thứ-cùng giờ theo mô tả thời tiết: tuyết lớn làm giảm 43% lưu lượng ban ngày, tuyết nhẹ 7%; mưa chỉ đáng kể khi là mưa lớn (kích thước điểm $\propto \sqrt{n}$).

Như vậy thời tiết **hiếm khi quan trọng nhưng khi có thì tác động mạnh và phi tuyến**. `weather_description`, biến mang thông tin cường độ, được giữ làm biến phân loại, và các mô hình cây được kỳ vọng khai thác nó tốt hơn mô hình tuyến tính.

1.4.6 Câu hỏi 2: Ngày lễ làm lưu lượng giảm bao nhiêu, và mọi ngày lễ có như nhau?

Trung bình một ngày lễ có **tổng lưu lượng thấp hơn ngày thường 28%** (62,317 so với 86,657 xe/ngày), gần bằng cuối tuần (-26%), và cao điểm sáng của ngày lễ chỉ bằng khoảng một nửa ngày thường. Con số trung bình che giấu khác biệt lớn. So sánh từng ngày lễ với một ngày bình thường (trung vị tổng lưu lượng của cùng thứ trong bốn tuần trước và sau, không tính ngày lễ) cho Hình 1.8:

- sáu ngày lễ lớn (Năm mới, Lễ Tạ ơn, Quốc khánh, Giáng sinh, Memorial Day, Labor Day) giảm 33–49%;
- Martin Luther King Jr Day và Washington's Birthday giảm 9–28%, vì nhiều nơi vẫn làm việc;
- Veterans Day và Columbus Day gần như không giảm (-4% đến 0%);
- các ngày **State Fair** của bang Minnesota, vốn không phải ngày nghỉ, thậm chí tăng 1–5%.



Hình 1.8: Từng ngày lễ so với một ngày bình thường cùng thứ: từ -49% (Năm mới) đến $+5\%$ (State Fair).

Một cờ `is_holiday` duy nhất sẽ trộn lẫn các tác động ngược chiều nhau, nên bộ đặc trưng có cả `is_holiday` và `is_major_holiday` (sáu ngày lễ lớn). Cả hai đều biết trước từ lịch.

1.4.7 Câu hỏi 3: Thống kê nào phát hiện được đoạn đóng đường?

Z-score toàn cục thất bại trên dữ liệu có mùa vụ, vì giá trị ban đêm trông như ngoại lai khi đặt cạnh giá trị ban ngày. Trước hết hồ sơ mùa vụ (trung vị của cùng giờ trong tuần) được trừ đi để có phần dư r_t, rồi phần dư được chuẩn hóa trong cửa sổ trượt 168 giờ đặt giữa theo hai cách:

$$z_t^{\text{std}} = \frac{r_t - \text{mean}_{168}(r)}{\text{std}_{168}(r)}, \qquad z_t^{\text{robust}} = \frac{r_t - \text{median}_{168}(r)}{1.4826 \cdot \text{MAD}_{168}(r)},$$

và một giờ bị đánh dấu khi $|z_t| > 3.5$ (ngưỡng Iglewicz–Hoaglin). Một *giờ đóng đường* được định nghĩa là giờ ban ngày (7h–19h) có dưới 300 xe trong khi giá trị thông thường của giờ đó trong tuần lớn hơn 3,000.

Bảng 1.3: Rolling mean/std so với rolling median/MAD trên giai đoạn nghiên cứu

Phương pháp	Số giờ bị đánh dấu	Giờ đóng đường bắt được (/14)	Giờ bị đánh dấu vào ngày lễ
Rolling mean / std	248 (1.0%)	0	52
Rolling median / MAD	1,016 (4.2%)	14	184



Hình 1.9: Đóng đường tháng 7/2016: rolling median/MAD bắt được 14/14 giờ đóng đường, rolling mean/std không bắt được giờ nào (hiệu ứng che lấp).

Khi đường bị đóng nhiều giờ liên tiếp, chính các giờ đó làm độ lệch chuẩn của cửa sổ phình to, nên z-score của chúng nhỏ lại và chúng tự che mình (*masking*). Ngày 23–24/7/2016, z-score robust xuống khoảng -8, trong khi z-score theo mean/std chỉ chạm -3 (Hình 1.9). Các ngày có nhiều giờ bị đánh dấu nhất là ngày lễ và ngày bão tuyết, tức các sự kiện có thật. Vì vậy giá trị mục tiêu được **giữ nguyên**: nếu làm sạch chúng trong giai đoạn test, điểm số sẽ đẹp một cách giả tạo. `is_outlier` chỉ dùng để phân tích lỗi, không bao giờ dùng làm đặc trưng, vì nó được tính bằng cửa sổ đặt giữa, tức có nhìn vào tương lai.

1.5 Chuẩn bị dữ liệu

1.5.1 Tạo đặc trưng

Mỗi dòng tại thời điểm t dự báo y_t chỉ bằng thông tin có sẵn tại $t-1$ (Bảng 1.4). Sau khi bỏ 168 giờ đầu chưa có lag tuần, còn 23,928 dòng với 21 đặc trưng số và 2 đặc trưng phân loại.

Bảng 1.4: Các đặc trưng và cách chống rò rỉ dữ liệu

Nhóm	Đặc trưng	Chống rò rỉ
Lag	y_{t-k} với k = 1, 2, 3, 24, 168 (từ ACF/PACF)	chỉ dùng $k \geq$ `HORIZON`
Rolling	trung bình và độ lệch chuẩn của mục tiêu trong 24 giờ qua	tính trên y đã dịch 1 giờ
Lịch	giờ, thứ, tháng dạng cặp sin/cos; `is_weekend`	biết trước
Ngày lễ	`is_holiday`, `is_major_holiday`	lịch ngày lễ biết trước
Thời tiết	nhiệt độ, mưa, tuyết, mây, `n_weather`, `weather_main`, `weather_description`	quan sát một giờ trước

Mã hóa sin/cos đặt 23h cạnh 0h và tháng 12 cạnh tháng 1, điều một số nguyên đơn thuần không làm được. Khác với cách làm tắt thường gặp, thời tiết được đưa vào với độ trễ một giờ, nên mô hình dùng thời tiết quan sát được lúc dự báo thay vì giả định có một dự báo thời tiết hoàn hảo.

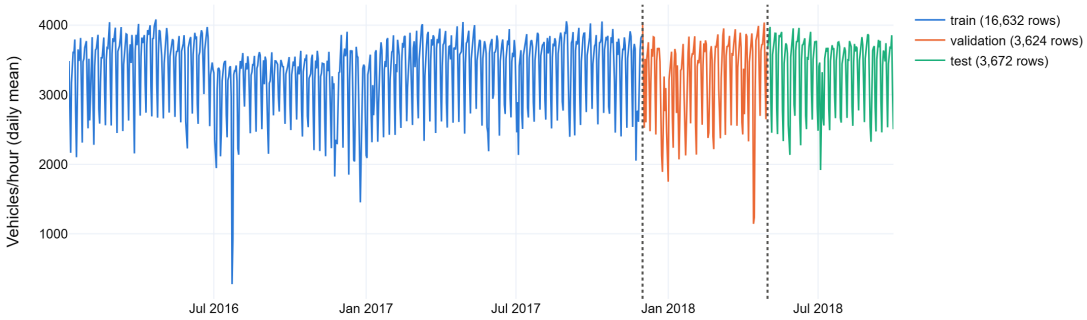
1.5.2 Chia train / validation / test theo thời gian

Dữ liệu được chia theo thời gian, không xáo trộn. Nếu chia ngẫu nhiên, y_{t-1} của một dòng test chính là mục tiêu của một dòng train, và mô hình sẽ được chấm điểm trên những giá trị nó gần như đã thấy.

Bảng 1.5: Chia theo thời gian (không xáo trộn)

Tập	Giai đoạn	Số dòng	TB (xe/giờ)	% nội suy	% giờ có tuyết
Train	08/01/2016 – 30/11/2017	16,632 (69.5%)	3,322	5.6	5.7
Validation	01/12/2017 – 30/04/2018	3,624 (15.1%)	3,240	0.5	17.6
Test	01/05/2018 – 30/09/2018	3,672 (15.3%)	3,358	0.2	0.0

Ba tập có trung bình gần nhau và cùng phân phối hai đỉnh nhưng khác nhau về mùa (Bảng 1.5, Hình 1.10): validation là đông–xuân với 17.6% số giờ có tuyết, còn test là mùa hè, không có tuyết. Vì vậy điểm trên tập test không nói gì về bão tuyết. Gần như toàn bộ giờ được nội suy nằm trong train; validation và test có ít nhất 99.5% là dữ liệu thật.



Hình 1.10: Chia theo thời gian: train → validation → test, không chồng lấn.

1.5.3 Mã hóa, chuẩn hóa và chống rò rỉ

Các đặc trưng số được chuẩn hóa bằng `StandardScaler` (cần cho Ridge; mô hình cây không bị ảnh hưởng), còn biến phân loại được mã hóa bằng `OneHotEncoder(handle_unknown="ignore")`, để một loại lần đầu xuất hiện trong test thành vector 0 thay vì gây lỗi. Cả hai bước nằm trong `Pipeline` của từng mô hình scikit-learn và chỉ được fit trên các dòng train, kể cả trong từng fold cross-validation. 23 đặc trưng trở thành 65 cột đầu vào. Trên tập train, y_{t-168} ($r = 0.95$), y_{t-1} (0.91) và y_{t-24} (0.87) là các biến tương quan tuyến tính mạnh nhất, tiếp theo là `hour_cos` (-0.77); mọi biến thời tiết đều có $|r| \leq 0.12$. Các lag 1–3 tương quan mạnh với nhau (≥ 0.72), nên mô hình tuyến tính được chọn là Ridge (có phạt L2) thay vì bình phương tối thiểu thông thường.

1.6 Mô hình và thiết lập thực nghiệm

Sáu cách tiếp cận được so sánh trên tập validation (Bảng 1.6).

Bảng 1.6: Các mô hình được so sánh

Mô hình	Lý do
Naive	dự báo = giá trị gần nhất đã biết y_{t-1}
Seasonal naive	dự báo = giá trị một chu kỳ trước, y_{t-24} hoặc y_{t-168}; thường khó vượt trên dữ liệu có mùa vụ
Ridge	tổ hợp tuyến tính của lag và lịch; phạt L2 giúp ổn định khi các lag tương quan với nhau
Random Forest	phi tuyến, lấy trung bình nhiều cây sâu
HistGradientBoosting	boosting trên cây, mạnh với dữ liệu dạng bảng đặc trưng
SARIMAX + Fourier	mô hình thống kê tham chiếu: hồi quy Fourier theo tuần với sai số AR(3)

SARIMAX với số hạng Fourier (dynamic harmonic regression). Vì seasonal ARIMA với $m = 168$ quá nặng, hình dạng tuần được mô tả bằng các số hạng Fourier, còn trí nhớ ngắn

hạn do phần sai số ARIMA đảm nhận:

$$y_t = c + \sum_{k=1}^{K} \left[a_k \sin \frac{2\pi k t}{168} + b_k \cos \frac{2\pi k t}{168} \right] + \beta^\top x_t + \eta_t, \qquad \eta_t \sim \text{AR}(3).$$

Các họa âm $k = 7, 14, 21, \ldots$ có chu kỳ 24 giờ, nên chu kỳ ngày cũng được bao gồm. x_t chứa các cờ ngày lễ và tương tác của chúng với ba họa âm ngày đầu tiên, vì ngày lễ làm thay đổi *hình dạng* của cả ngày. Bậc $(3, 0, 0)$ được chọn theo PACF và các kiểm định tính dừng ($d = 0$). K được chọn trên validation trong các giá trị 21, 42 và 63, và dự báo là một bước: tham số được fit trên train, các giờ validation chỉ được lọc qua mô hình, nên dự báo cho giờ t chỉ dùng quan sát đến $t - 1$, giống hệt các mô hình khác.

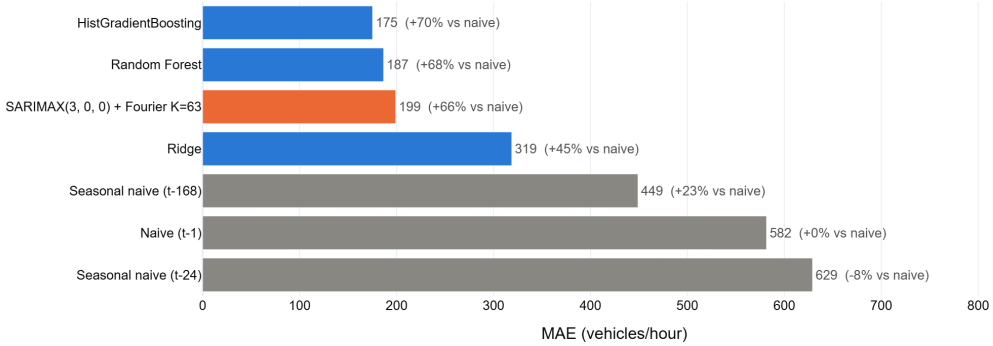
Tinh chỉnh siêu tham số. HistGradientBoosting được tinh chỉnh bằng `GridSearchCV` trên learning rate, số vòng lặp và số lá, dùng `TimeSeriesSplit` trên tập train: mỗi fold luôn học trên quá khứ và đánh giá trên giai đoạn ngay sau đó, khác với k-fold thông thường. Mô hình có MAE validation tốt nhất được fit lại trên train + validation (dữ liệu gần nhất quan trọng nhất cho dự báo) và chấm điểm một lần trên tập test. Với `EVAL_ON_OBSERVED_ONLY`, các giờ nội suy bị loại khỏi mọi phép tính điểm, và MAPE chỉ tính trên các giờ có mục tiêu khác 0.

1.7 Kết quả và đánh giá

1.7.1 So sánh mô hình trên tập validation

Bảng 1.7: So sánh các mô hình chuỗi thời gian trên tập validation (12/2017 – 04/2018)

Mô hình	MAE	RMSE	MAPE (%)	R^2	Skill so với naive
HistGradientBoosting (tuned)	**171.7**	**267.4**	**7.75**	**0.982**	**+70.5%**
HistGradientBoosting (mặc định)	175.3	272.4	7.98	0.981	+69.9%
Random Forest	186.6	305.5	8.00	0.976	+67.9%
SARIMAX(3,0,0) + Fourier $K = 63$	199.1	334.1	11.47	0.971	+65.8%
Ridge	318.8	447.4	17.21	0.949	+45.2%
Seasonal naive ($t - 168$)	449.1	781.5	18.13	0.843	+22.8%
Naive ($t - 1$)	581.7	802.3	27.35	0.835	0.0%
Seasonal naive ($t - 24$)	629.1	1,067.1	29.13	0.708	-8.2%



Hình 1.11: MAE trên validation (xám = baseline, cam = mô hình thống kê): mọi mô hình đều vượt các baseline naive, và HistGradientBoosting tốt nhất.

Mọi mô hình đều vượt xa các baseline naive (Bảng 1.7, Hình 1.11). Baseline tốt nhất là **seasonal naive "cùng giờ tuần trước"** (MAE 449), đúng như ACF đã gợi ý; "cùng giờ hôm qua" còn tệ hơn naive thông thường (629 so với 582) vì nó chép một ngày Chủ nhật sang thứ Hai. Hai mô hình cây dẫn đầu vì kết hợp được lag với giờ, thứ và cờ ngày lễ một cách phi tuyến. **SARIMAX + Fourier đứng thứ ba với khoảng cách nhỏ** (MAE 199), vượt xa Ridge. Tăng số họa âm giúp rất nhiều ($K = 21$: MAE 317, $K = 42$: 224, $K = 63$: 199) vì các đỉnh giờ cao điểm ngày thường rất nhọn; hệ số AR(1) bằng 0.86 cho thấy sai số vẫn tương quan từ giờ này sang giờ kế tiếp. SARIMAX chỉ dùng lịch và quá khứ của chuỗi, hoàn toàn diễn giải được, nhưng mỗi lần fit mất 10–30 giây thay vì khoảng một giây. Ridge tuyến tính theo `hour_sin` / `hour_cos` nên không vẽ được một ngày có hai đỉnh, và gần như chỉ dựa vào các lag. Tinh chỉnh (learning rate 0.05, 31 lá, 300 vòng lặp; MAE cross-validation trên train là 190) chỉ cải thiện MAE validation của HistGradientBoosting 2%, từ 175 xuống 172: cấu hình mặc định đã gần tối ưu.

1.7.2 Kết quả trên tập test

Bảng 1.8: Mô hình cuối cùng trên tập test (05/2018 – 09/2018, chỉ các giờ có dữ liệu thật)

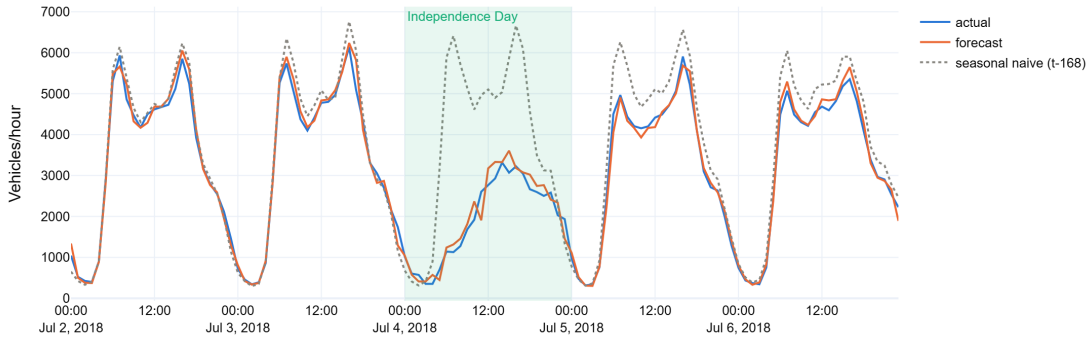
Mô hình	MAE	RMSE	MAPE (%)	R^2	Skill so với naive
Naive ($t-1$)	582.8	810.1	26.04	0.828	0.0%
Seasonal naive ($t-24$)	512.0	981.7	21.99	0.748	+12.2%
Seasonal naive ($t-168$)	257.2	535.1	10.41	0.925	+55.9%
HistGradientBoosting (tuned)	**131.5**	**201.8**	**5.34**	**0.989**	**+77.4%**

Trên tập test, mô hình cuối cùng đạt **MAE 131.5 xe/giờ**, giảm 77.4% so với dự báo naive và chỉ bằng khoảng một nửa sai số của baseline tốt nhất (Bảng 1.8). Ở thang ngày, dự báo bám sát chuỗi thực tế; ở thang giờ, nó bắt được mọi giờ cao điểm, trong khi dự báo naive luôn trễ một giờ (Hình 1.12). MAE trên test thấp hơn trên validation (172) vì giai đoạn test là mùa hè không có tuyết, dễ dự báo hơn.



Hình 1.12: Dự báo so với thực tế trên test: MAE 132 xe/giờ (skill +77% so với naive). Trên: trung bình ngày trong toàn bộ giai đoạn test; dưới: hai tuần cuối theo từng giờ, dự báo naive trễ một giờ.

Đặc trưng ngày lễ có giúp ích không? Giai đoạn test chứa Memorial Day, Quốc khánh (4/7) và Labor Day. Quốc khánh 2018 rơi vào thứ Tư: dự báo seasonal naive lặp lại một thứ Tư bình thường và sai trung bình 1,957 xe/giờ, trong khi mô hình, nhờ biết `is_holiday` / `is_major_holiday` và thấy các lag buổi sáng thấp, chỉ sai **235 xe/giờ** (Hình 1.13). Đây là câu trả lời thực tế cho câu hỏi về ngày lễ ở phần EDA.

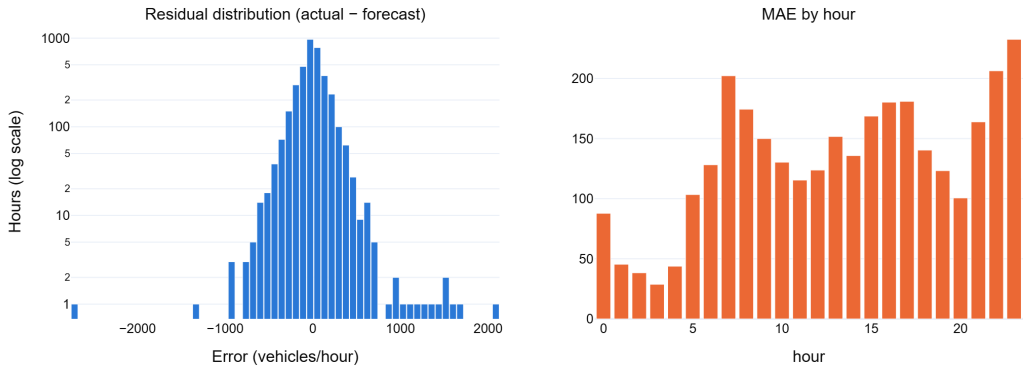


Hình 1.13: Quốc khánh Mỹ, 4/7/2018: MAE của mô hình là 235 xe/giờ so với 1,957 của dự báo seasonal naive.

1.7.3 Phân tích lỗi và tầm quan trọng của đặc trưng

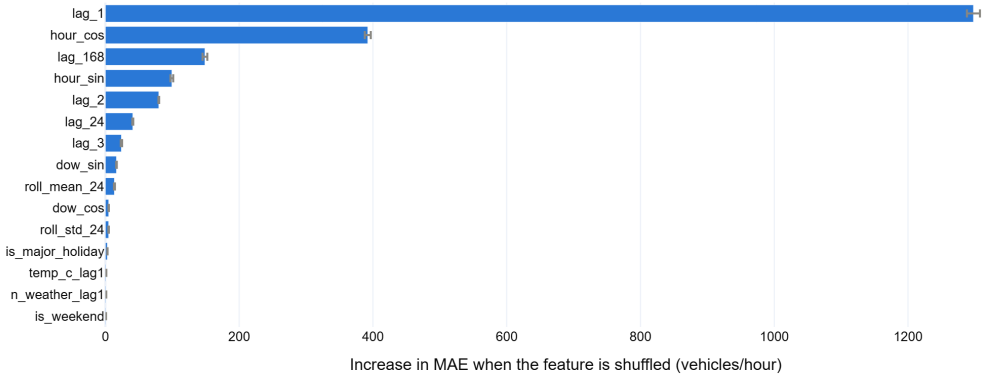
Phần dư không bị lệch (trung bình -3 xe/giờ) và đối xứng với đuôi dày (Hình 1.14). MAE thấp nhất vào ban đêm (dưới 50 lúc 1–4h) và cao nhất lúc **23h ($\approx$ 230)** và ở **đỉnh sáng 7h ($\approx$ 200)**:

lúc lưu lượng tăng vọt buổi sáng và lúc tối muộn là khi một giờ lịch sử cho biết ít nhất về giờ tiếp theo.



Hình 1.14: Phần dư trên test: trung bình -3 xe/giờ (không lệch); MAE lớn nhất lúc 23h và ở đỉnh sáng 7h.

Permutation importance trên tập test xác nhận kết quả EDA (Hình 1.15): xáo trộn y_{t-1} làm MAE tăng khoảng 1,300, tiếp theo là `hour_cos` (≈ 390) và y_{t-168} (≈ 150), tức trí nhớ ngắn hạn, chu kỳ ngày và chu kỳ tuần. Các đặc trưng thời tiết và ngày lễ gần như không đóng góp *trên giai đoạn test này*: không có tuyết và chỉ có ba ngày lễ, nên giá trị của chúng không thể hiện ra, dù EDA cho thấy chúng quan trọng vào mùa đông và ngày lễ.



Hình 1.15: Permutation importance trên tập test (mức tăng MAE khi xáo trộn một đặc trưng): y_{t-1} quan trọng nhất, rồi đến giờ trong ngày và y_{t-168}.

Các sai số lớn nhất. 60% trong 50 sai số lớn nhất trên test rơi vào các giờ bị bộ phát hiện robust đánh dấu ngoại lai, dù các giờ này chỉ chiếm 3.1% giai đoạn test. Vậy những lần dự báo sai nặng nhất là do **sự kiện bất thường**, không phải lỗi có hệ thống. Lớn nhất là ngày 21/5/2018 lúc 13h: lưu lượng tụt đột ngột còn 2,040 xe (nhiều khả năng do sự cố) mà mô hình chỉ "thấy" sau một giờ, nên sai hai lần: lúc tụt và lúc hồi lại. Nhiều sai số khác là các buổi tối muộn tháng 9/2018 với 2,700–3,900 xe lúc 23h thay vì khoảng 1,300 như thường lệ; dữ liệu không cho biết nguyên nhân. Một mô hình dự báo trước một giờ không thể lường trước các trường hợp này nếu không có dữ liệu sự cố hoặc sự kiện.

Dự báo trên dữ liệu mới. Sau khi fit lại trên toàn bộ 23,928 giờ dùng được, mô hình dự báo **571 xe** cho 0h thứ Hai 01/10/2018, tiếp nối đà giảm của đêm Chủ nhật (954 xe lúc 23h). Mọi đầu vào của dòng này đều biết được tại thời điểm dự báo: lag và thời tiết lấy từ 23h Chủ nhật trở về trước, còn lịch và cờ ngày lễ biết trước.

1.8 Kết luận

1. **Hai chu kỳ lồng nhau chi phối chuỗi.** MSTL quy 79% phương sai cho chu kỳ ngày và 15% cho chu kỳ tuần, so với 1% cho xu hướng; giờ đông nhất gấp 15 lần giờ vắng nhất, còn tháng đông nhất chỉ hơn tháng vắng nhất 12%.

2. **Giá trị quá khứ nhiều thông tin nhất là cùng giờ tuần trước** (ACF 0.94 ở lag 168) và giờ liền trước (0.91); đây cũng là các đặc trưng quan trọng nhất của mô hình cuối cùng.

3. **Các ngày lễ không giống nhau**: trung bình -28%, từ -49% (Năm mới) đến $+5\%$ (State Fair). Nhờ các cờ ngày lễ, mô hình chỉ sai 235 xe/giờ vào Quốc khánh 2018 thay vì 1,957.

4. **Thời tiết chỉ quan trọng khi cực đoan**: tuyết -10.6% và tuyết lớn -43% so với cùng thứ-cùng giờ, mọi loại thời tiết khác trong khoảng $\pm 3\%$.

5. **Cần thống kê robust để phát hiện bất thường**: rolling median/MAD bắt được 14/14 giờ đóng đường, rolling mean/std không bắt được giờ nào do hiệu ứng che lấp; các giờ bị đánh dấu chiếm 60% các sai số lớn nhất trên test.

6. **Mô hình cây thắng, ARIMA là mốc tham chiếu vững**: HistGradientBoosting đã tinh chỉnh giảm 77% MAE so với naive trên test (MAE 131.5); SARIMAX với số hạng Fourier theo tuần và sai số AR(3) đạt MAE validation 199, vượt Ridge và mọi baseline.

1.9 Hạn chế và hướng phát triển

- **Dữ liệu:** chỉ một trạm đếm và một chiều đi (hướng tây); không có thông tin về sự cố, công trình hay sự kiện, vốn là nguyên nhân của các sai số lớn nhất. Nhãn ngày lễ chỉ lấy từ chính tập dữ liệu.

- **Phương pháp:** chỉ dự báo trước một giờ; thời tiết là thời tiết quan sát một giờ trước, không phải dự báo thời tiết. Các giờ được nội suy (4.2%, phần lớn trong train) vẫn được dùng để huấn luyện.

- **Đánh giá:** chỉ một lần chia theo thời gian; giai đoạn test (hè 2018) không có tuyết và chỉ có ba ngày lễ, nên hành vi mùa đông chỉ được đo trên validation. SARIMAX chỉ được so sánh trên validation vì tập test dành riêng cho mô hình được chọn.

- **Hướng phát triển:** tầm dự báo dài hơn (ví dụ trước 24 giờ, khi không còn y_{t-1} và dự báo phải dựa vào lịch và lag tuần), đánh giá rolling-origin trên nhiều cửa sổ test kể cả một cửa sổ mùa đông, và bổ sung dữ liệu sự cố hoặc sự kiện để giải thích các sai số lớn nhất.

1.10 Tài liệu tham khảo

- J. Hogue, *Metro Interstate Traffic Volume*, UCI Machine Learning Repository, 2019. CC BY 4.0.
- K. Bandara, R. J. Hyndman, C. Bergmeir, *MSTL: A Seasonal-Trend Decomposition Algorithm for Time Series with Multiple Seasonal Patterns*, 2021.
- X. Wang, K. Smith, R. J. Hyndman, *Characteristic-Based Clustering for Time Series Data*, Data Mining and Knowledge Discovery 13 (2006) 335–364.
- R. J. Hyndman, G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed., OTexts, 2021 (dynamic harmonic regression, mục 10.5).
- B. Iglewicz, D. C. Hoaglin, *How to Detect and Handle Outliers*, ASQC Quality Press, 1993.
- F. Pedregosa et al., *Scikit-learn: Machine Learning in Python*, Journal of Machine Learning Research 12 (2011) 2825–2830.
- S. Seabold, J. Perktold, *Statsmodels: Econometric and Statistical Modeling with Python*, Proc. 9th Python in Science Conference, 2010.